시계열 데이터 수집

시계열 데이터의 수집과 처리

TIME-SERIES

저자
Chunghun Ha

소속
Hongik University

공개
2024년 4월 7일

MODIFIED
2026년 3월 8일

시계열 데이터 수집 과정

- 다양한 시계열 소스(IoT 센서, 거래 트랜젝션 등)가 있음
- 시계열을 포함한 모든 데이터는 분석을 위해서는 디지털 데이터로 변환하여 ***데이터베이스에 저장***하고,
- 응용 프로그램에서 데이터베이스에 저장된 디지털데이터를 쿼리(SQL), 파일(CSV), API(XML, JSON) 등을 통하여 ***전송 및 로딩***한 후,
- ***데이터프레임과 같은 유형이므로 변환***하여 사용함

시계열 유형에 따른 수집방법

- ***연속 시계열은 시간기반 샘플링***을 통하여 ***이산 시계열로 변환***하여 데이터베이스 등으로 저장
- ***이산 시계열은 필요에 따라 피쳐 엔지니어링을 통해 집계***하여 활용
- ***사건 시계열은 사건 발생시마다 데이터를 수집***하여 데이터 베이스에 저장

📊 그림: 시계열 데이터 처리 과정

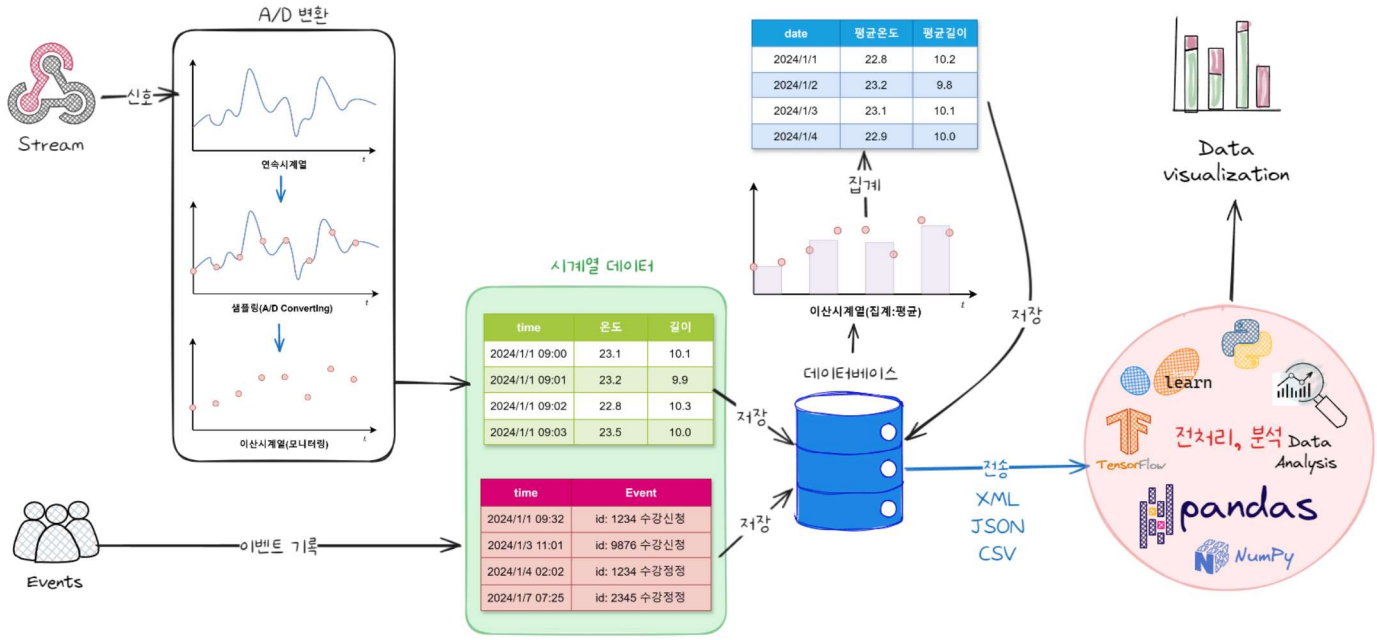

시계열 데이터 수집 기술

샘플링(Sampling)

> 주로 연속시계열 데이터를 모니터링할 때 사용하며, 일정한 시간 간격으로 대상을 관측하여 데이터를 수집하는 방법

- 샘플링 주기가 짧을수록 데이터의 정확도는 높아지지만, 데이터의 양은 증가함
- 샘플링 방법
  - ***시간기반 샘플링(Time-based sampling)*** = A/D(Analog to Digital) 변환
    - 아날로그 데이터 또는 연속 시계열을 ***일정한 시간 간격***으로 데이터를 수집하는 방법
    - 예) 1초마다 데이터를 수집
  - ***사건기반 샘플링(Event-based sampling)***
    - ***이벤트가 발생할 때마다*** 데이터를 수집하는 방법
    - 예) 네트워크 패킷이 발생할 때마다 데이터를 수집

집계(Aggregation)

> 샘플링된 데이터(또는 이산 데이터)를 특정 기준(합계, 평균 등)에 따라 집계하여 데이터를 수집하는 방법

- ***데이터 용량을 줄이기 위해 데이터 수집단계에서 집계***를 수행할 수도 있고, ***데이터를 분석할 때 피쳐엔지니어링 단계에서 집계***를 수행할 수도 있음

📊 그림: 집계

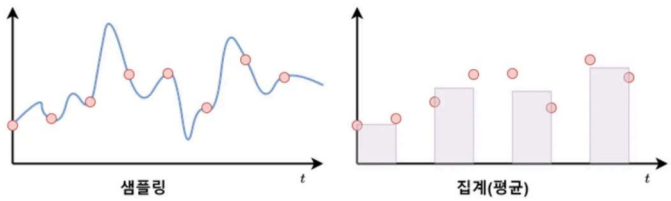

시계열 데이터의 전송

- 디지털화 된 시계열 데이터는 통신 네트워크를 이용하여 데이터베이스로 전송

시계열 데이터 모델

> ***누가(Who), 언제(When), 어디서(Where), 무엇을(What)을*** 저장하였는지에 대한 정보 모델

📊 그림: 시계열 데이터 모델

시계열 데이터 전송 포맷

- CSV(Comma-Separated Values)
  - 데이터 베이스에 저장된 시계열 데이터를 ***파일로 저장하고 전송***할 때 CSV을 많이 사용
  - 테이블 형태의 ***2차원 구조***의 데이터에 적합
- JSON(JavaScript Object Notation), XML(Extensible Markup Language)
  - ***다중 트리구조***의 복잡한 데이터를 저장하고 전송할 때 사용
  - ***API를 통해 데이터를 전송***할 때 많이 사용

> ⓘ 데이터 직렬화
>
> - 직렬화(serialization)는 컴퓨터 메모리에 있는 ***객체를 저장하거나 네트워크를 통해 전송하기 위해*** ***바이트 스트림으로 변환***하는 과정
> - 역직렬화(deserialization)는 ***바이트 스트림으로부터 객체를 복원***하는 과정
>
> 📊 그림: 직렬화와 역직렬화[1]
>
> 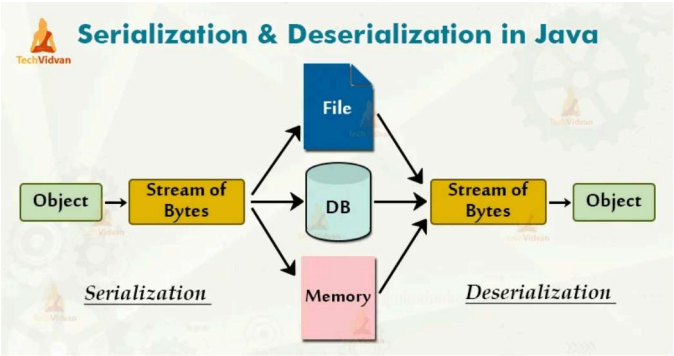
>
>
> - 데이터들의 메모리 구조는 ***값 형식(Value Type)***과 ***참조 형식(Reference Type)***이 있음
> - 값 형식은 ***값 자체를 저장***하고 참조 형식은 ***값이 저장된 주소를 저장***
> - 참조 형식의 데이터를 바로 전송하게 되면, 값이 전달되지 않고 메모리 주소가 전달 ➔ 직렬화를 통해 참조 형식의 데이터를 ***값 형식으로 저장하고 이를 전송***에 사용
> - 데이터 직렬화 언어로는 YAML, XML, JSON 등이 있음

📊 그림: 직렬화 전송 원리[2]

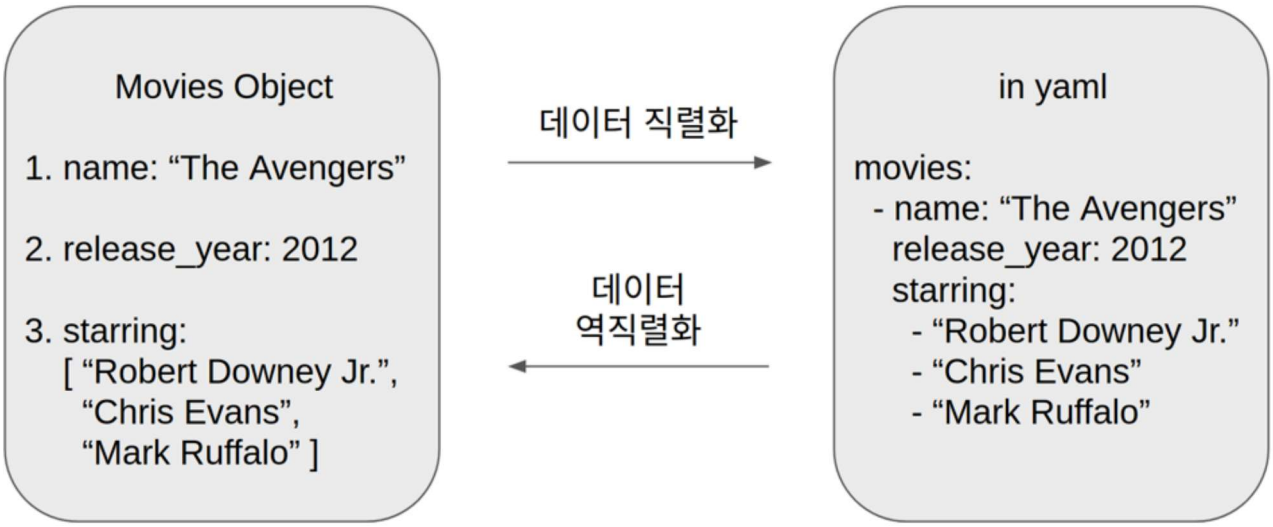

시계열 데이터의 저장 및 처리

시계열 데이터베이스

> **시계열 데이터베이스(Time Series Database, TSDB)**는 시간과 관련된 데이터분석(기간 내 최고, 최저, 합, 평균, 분산 등)을 위해 기존의 관계형 데이터베이스(RDB, Relational DB)보다 ***빠르게 데이터를 저장 및 집계***할 수 있도록 만들어진 데이터베이스

- 일반적으로 **NoSQL(Not Only SQL)** 데이터베이스를 사용
- 현재 많이 사용되는 시계열 데이터베이스는 InfluxDB, Prometheus, Graphite 등이 있음

📊 그림: TPCx-IoT(IoT 환경에서의 성능시험을 위한 벤치마크) 개요[3]

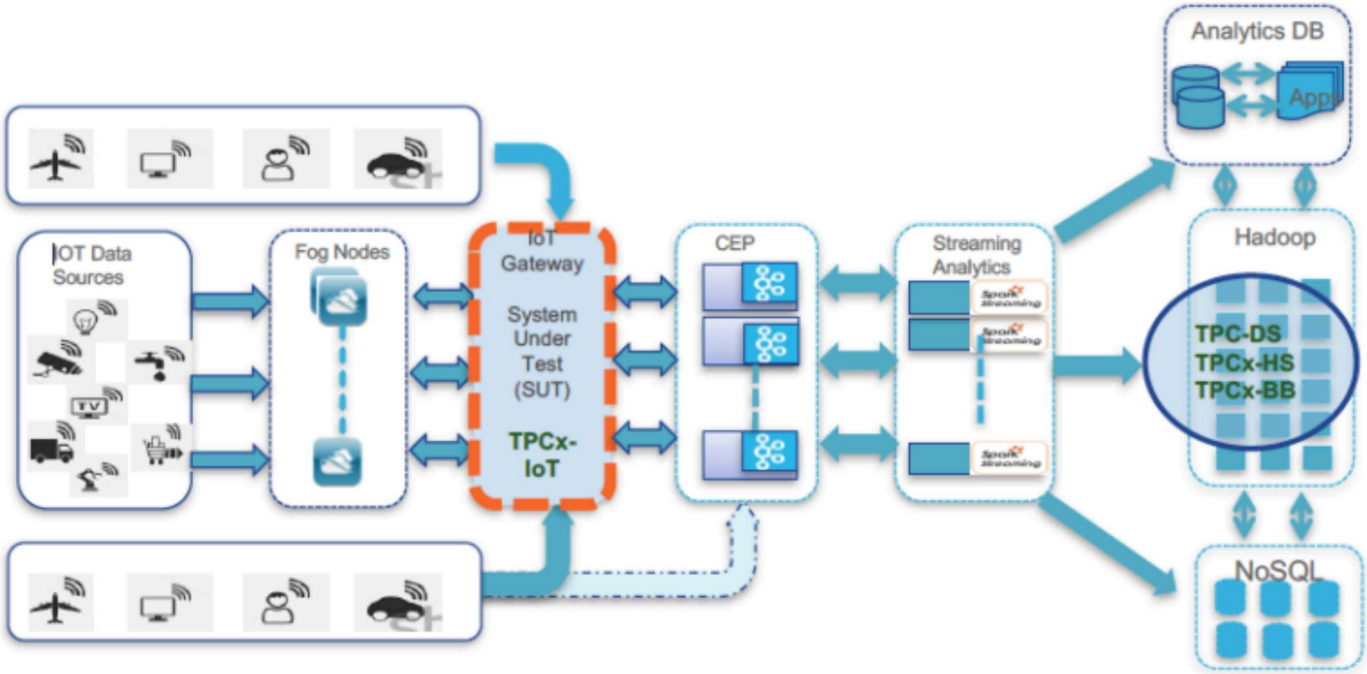

시계열 데이터베이스(TSDB)와 관계형 데이터베이스(RDB)의 성능상 차이점

- TSDB는 먼저 메모리 영역에 데이터를 저장한 후 한 번에 모아서 디스크 영역으로 저장하기 때문에 ***쓰기 성능이 뛰어남***
- TSDB는 시간의 순으로 디스크에 정렬되어 있기 때문에 ***시간에 대한 연산, 변환, 집계에서 RDB 보다 성능이 우수함***
- RDB는 필요한 key마다 index를 정의하고 관리하기 때문에 ***속성이 연관된 데이터들의 조합을 뽑아낼 때에는 RDB가 TSDB 보다 빠름***

시리즈, 데이터프레임

- 시리즈(Series)와 데이터프레임(DataFrame)은 Pandas의 데이터 구조
- 시리즈는 센서데이터와 같이 시간인덱스에 값만 있는 경우에 주로 사용
- 데이터 프레임은 여러 피쳐들이 복합적으로 측정되는 경우에 사용

📊 그림: Pandas의 데이터 구조

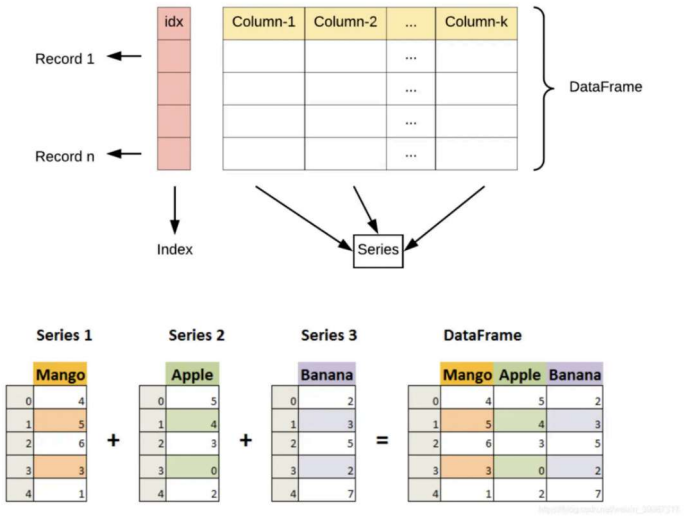

시계열 데이터 소스

데이터 직접 수집

- ***기업 데이터***: POS(Point of Sales), ERP(Enterprise Resource Planning), CRM(Customer Relationship Management) 등의 데이터베이스에서 수집
- ***생체 데이터***: 심전도, 혈압, 혈당, 체온 등의 생체 데이터를 측정하여 수집
- ***센서 데이터***: 온도, 습도, 가속도, 자이로스코프, GPS 등의 센서 신호를 수집

공공 데이터

데이터 소스	설명	URL
공공데이터포털	정부·공공기관 데이터 (교통, 환경, 인구, 경제 등)	data.go.kr
서울 열린데이터광장	서울시 교통, 환경, 생활 등 시계열 데이터	data.seoul.go.kr

데이터 소스	설명	URL
기상자료개방포털	기온, 강수량, 풍속, 습도 등 기상 시계열	data.kma.go.kr
한국전력 전력통계	전력 수요·공급, 발전량 시계열	epsis.kpx.or.kr
통계청 KOSIS	경제, 인구, 고용, 물가 등 국가 통계 시계열	kosis.kr
한국은행 경제통계	금리, 환율, GDP, 통화량 등 경제 시계열	ecos.bok.or.kr
FRED	미국 연방준비은행 경제 데이터 (금리, GDP, CPI 등)	fred.stlouisfed.org

금융 데이터 API

라이브러리	설명	설치
`FinanceDataReader`	한국·미국 주식, 환율, 암호화폐 시세	`pip install finance-datareader`
`yfinance`	Yahoo Finance 글로벌 주식·지수·ETF 시세	`pip install yfinance`
`pykrx`	KRX(한국거래소) 주식·ETF 일별 시세	`pip install pykrx`
`fredapi`	FRED 경제 시계열 API 래퍼	`pip install fredapi`

오픈 데이터세트

데이터세트	설명	URL
Google Dataset Search	키워드 기반 데이터세트 검색 엔진	datasetsearch.research.google.com
UCI ML Repository	머신러닝 벤치마크 데이터세트 (분류, 회귀, 시계열)	archive.ics.uci.edu
Kaggle Datasets	시계열 예측·이상탐지 경진대회 데이터 다수	kaggle.com/datasets
Numenta NAB	시계열 이상탐지 벤치마크 (서버, IoT, SNS 등)	github.com/numenta/NAB
Monash Forecasting	시계열 예측 벤치마크 30+개 데이터세트 모음	forecastingdata.org
TimeseriesClassification	UCR/UEA 시계열 분류 아카이브 (150+개)	timeseriesclassification.com
PhysioNet	심전도·뇌파 등 생체신호 시계열 데이터	physionet.org

토이 데이터세트

라이브러리	데이터세트	설명
`darts.datasets`	AirPassengers, ETTh, IceCream 등	Darts 내장 시계열 예측·이상탐지 데이터

라이브러리	데이터세트	설명
`sktime.datasets`	airline, shampoo_sales 등	sktime 내장 시계열 분류·예측 데이터
`statsmodels.datasets`	sunspots, co2, macrodata 등	통계모형 검증용 시계열 데이터
`sklearn.datasets`	load_diabetes 등	scikit-learn 내장 데이터 (일부 시계열 활용 가능)

각주

1. https://gyoogle.dev/blog/computer-language/Java/Serialization.html ↩
2. https://blogharu.github.io/cs/general/01.data_serialization.html ↩
3. https://www.e4ds.com/sub_view.asp?ch=1&t=0&idx=11144 ↩

Copyright 2026, Chunghun Ha, Hongik University